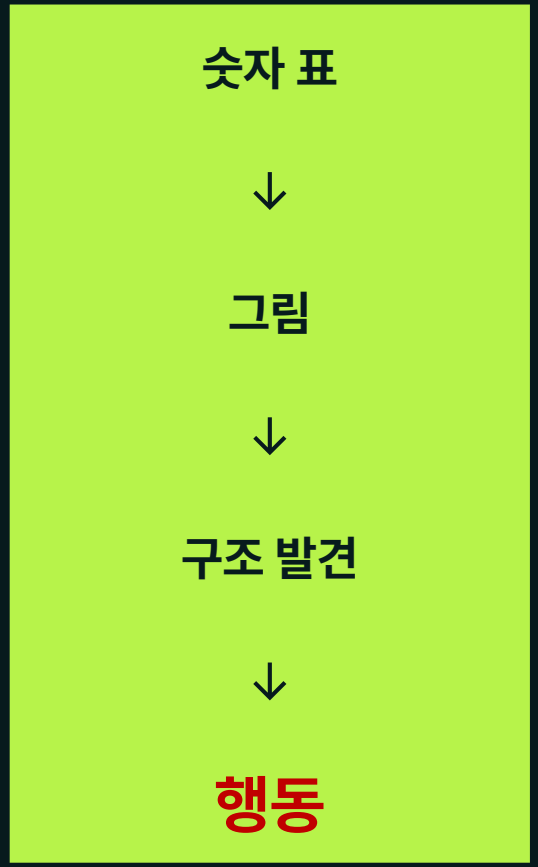
시각화의 두 고전
나이팅게일과 앤스컴

숫자 표가 움직이지 못한 사람을 그림이 움직였다



데이터 시각화 · 왜 시각화인가

시각화는 우선순위와 숨은 구조를 드러냅니다

두 고전은 시각화가 하는 서로 다른 두 가지 일을 대표한다

NIGHTINGALE · 1858

무엇을 바꿔야 하는가

- 사망 원인별 규모 비교
- 개혁 우선순위 제시

행동의 우선순위를 보인다

ANSCOMBE · 1973

숫자는 무엇을 놓치는가

- 같은 요약통계량
- 전혀 다른 데이터 구조

숨은 구조를 보인다

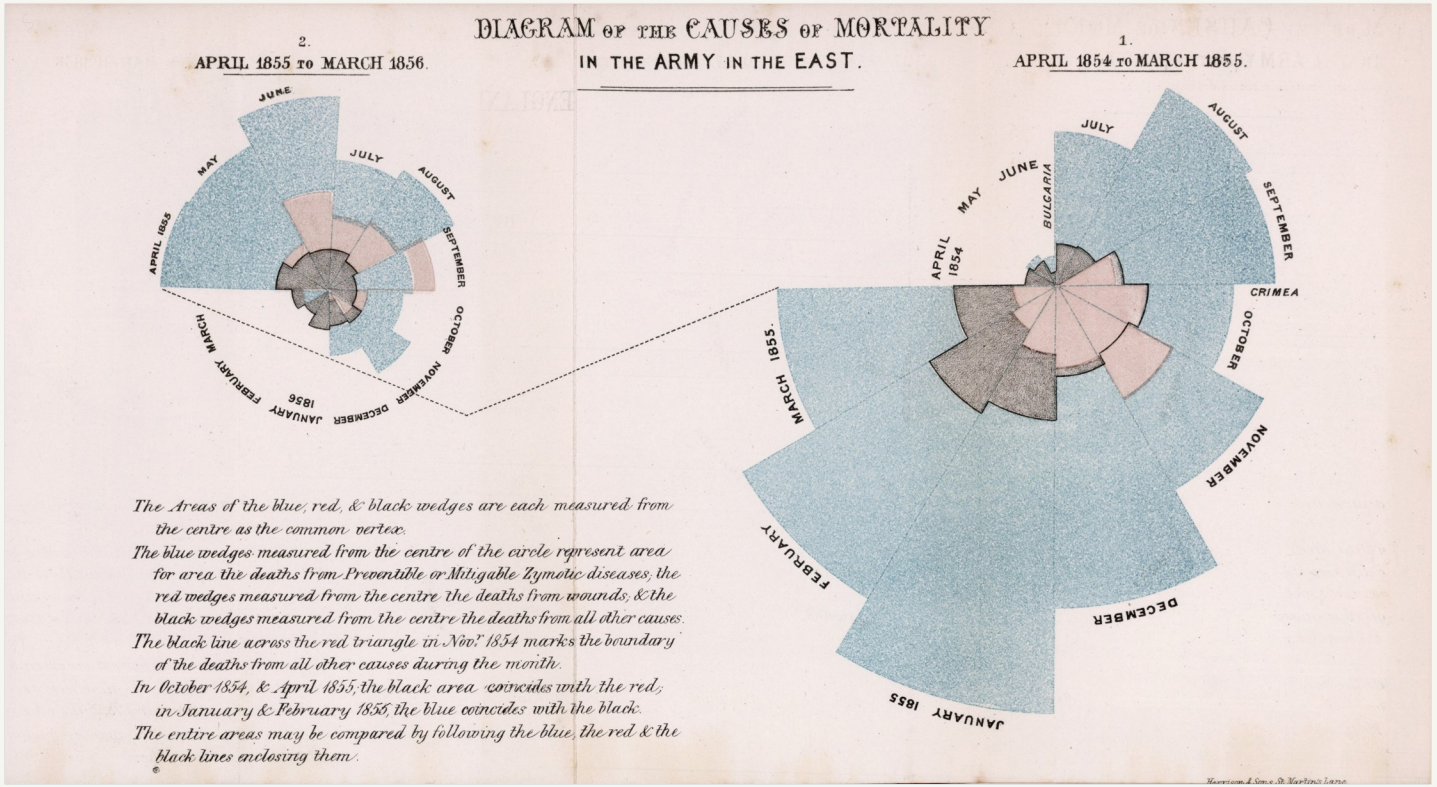
표는 결과를 요약하고, 그림은 판단의 근거를 보여 줍니다

01

나이팅게일의 장미 도표

Florence Nightingale · Diagram of the Causes of Mortality in the Army in the East (1858)

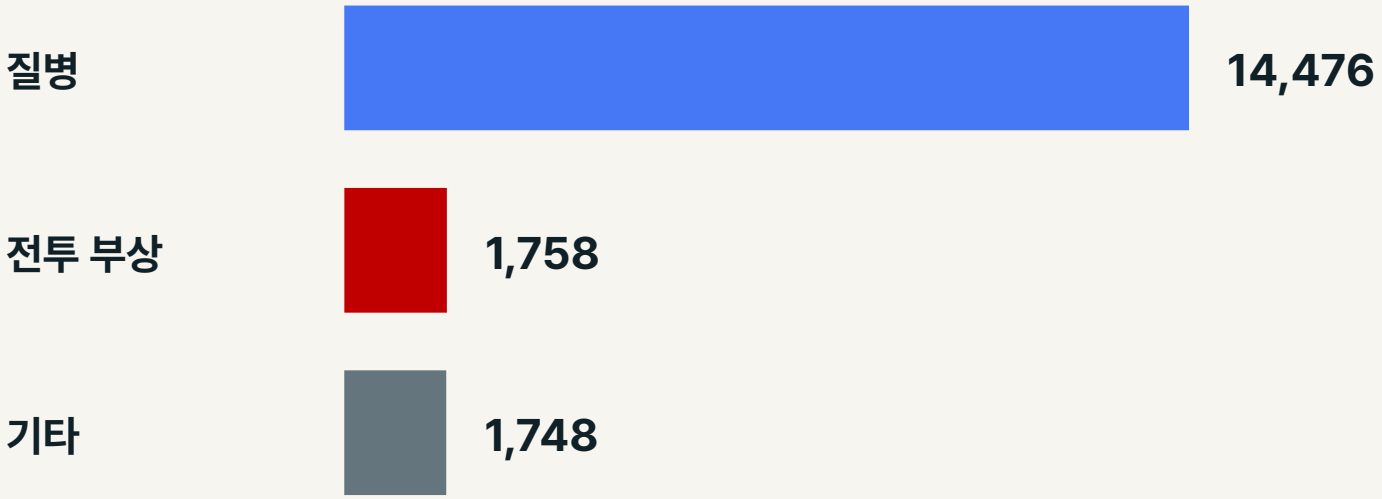
크림전쟁 사망의 대부분은 예방 가능한 질병이었습니다



※ 원본: Nightingale(1858), 퍼블릭 도메인 · 오른쪽 1854.4~1855.3, 왼쪽 1855.4~1856.3 · 파랑 질병, 빨강 부상, 검정 기타

24개월 사망자 약 1만 8천 명 중 80%가 질병이었습니다

1854년 4월 ~ 1856년 3월 동방 원정군 월별 사망자 수의 합계(명)



KEY INSIGHT

질병 사망 8.2배

전투 부상 대비 (14,476명)

첫해 11,157명 → 둘째 해 3,319명

질병 사망은 둘째 해 크게 감소

전쟁터의 주된 사망 원인은 적군이 아니라 병영의 질병이었습니다

장미 도표는 개혁의 필요성을 보였지만 인과를 증명하지는 않습니다

슬라이드 문구는 '증명'이 아니라 '설득'으로 쓴다

보여주는 것

원인별 사망의 크기

- 질병 사망의 압도적 비중
- 시기별 사망률 감소

위생 개혁의 필요성 설득

보여주지 못하는 것

개별 조치의 효과

- 위생 조치의 인과효과
- 다른 요인과의 분리

인과는 별도 설계로 검증

권장 문구: 예방 가능한 질병 사망이 전투 사망보다 훨씬 많음을 보여 개혁을 설득했다

02

앤스컴의 사중주

Francis J. Anscombe(1918–2001, 영국 통계학자) · Graphs in Statistical Analysis (1973)

네 묶음의 요약통계량은 반올림하면 같습니다

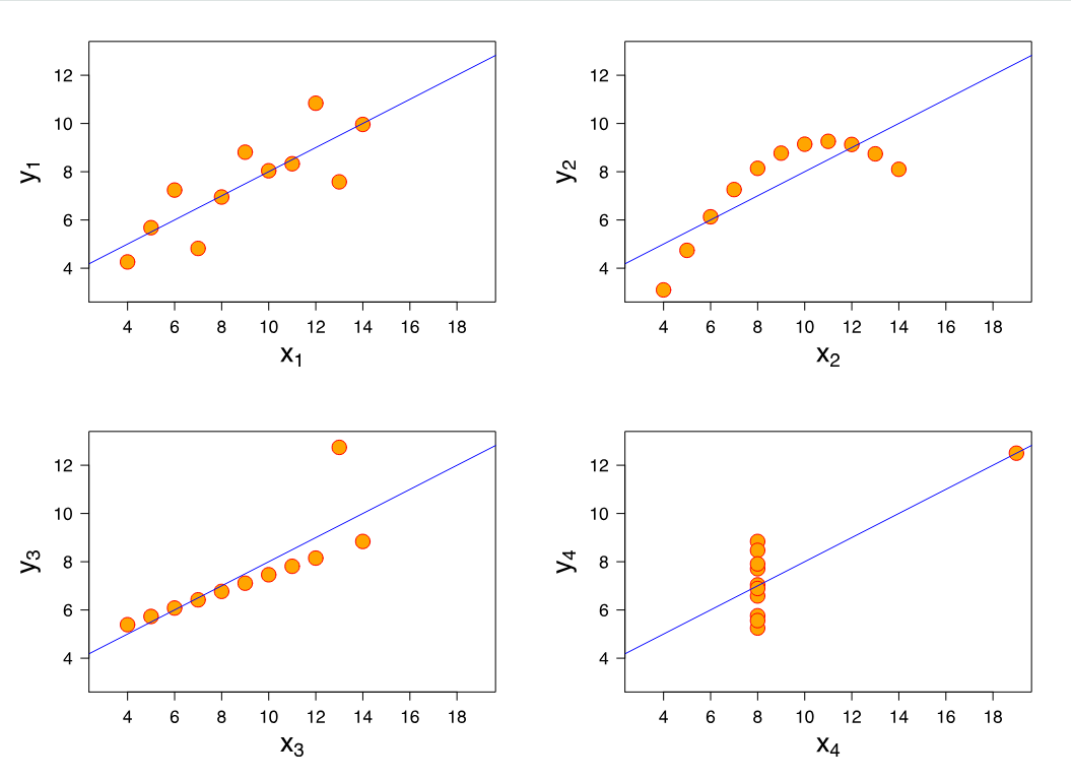
각 묶음은 관측치 11개 — 평균·분산·상관계수·회귀직선을 비교한 결과

$$\bar{x} = 9, \qquad \bar{y} \approx 7.50$$
$$r \approx 0.816, \qquad \hat{y} \approx 3.00 + 0.500\,x$$

묶음	x 평균	y 평균	y 분산	상관계수
I	9.00	7.50	4.13	0.816
II	9.00	7.50	4.13	0.816
III	9.00	7.50	4.12	0.816
IV	9.00	7.50	4.12	0.817

'평균의 함정'보다 '요약통계량의 함정'이 정확한 이름입니다

점을 찍으면 직선·곡선·이상치·레버리지로 갈립니다



※ 그림: Anscombe(1973) Figure 1을 원자료로 다시 그린 공개 도판 (Wikimedia Commons, CC BY-SA)

같은 회귀식이라도 적절한 분석은 묶음마다 다릅니다

회귀표만 보면 네 묶음 모두 '선형회귀가 잘 맞는다'고 결론 내리게 된다

패널	실제 모습	분석할 때의 의미
I	직선 주변에 흩어짐	선형회귀가 비교적 적절
II	곡선을 따라 배열	직선으로는 관계의 형태를 놓침
III	한 점만 크게 벗어남	이상치가 회귀 결과를 왜곡
IV	x=8에 몰리고 한 점만 멂	그 한 점이 기울기를 좌우

숫자만 보지 말고 그려 봐야 어떤 모형이 맞는지 압니다

나이팅게일: 그림은 행동의 우선순위를 보인다.

앤스컴: 그림은 숫자가 숨긴 구조를 보인다.

숫자만 보지 말고 그려 보라.

회귀표를 내기 전에 산점도부터 그린다.