★ 위임 사다리 · 0~4단계

AI 업무 위임 사다리

Delegation Ladder — AI에게 어디까지 맡길 것인가

단계별 정의 · 통제 장치 · 승급 조건 · 금융 적용

AI가 행동하는 범위와 사람이 승인하는 지점으로 위임 수준을 다섯 단계로 나눈다.
업무 전체가 아니라 업무 단위마다 단계를 정하고, 측정한 결과로 한 단계씩 올린다.

세 가지 메시지

위임 수준은 업무 단위로 정하고 측정으로 올린다

이 덱의 결론 — 단계 정의, 판단 기준, 운영 원칙

1

단계는 승인 지점으로 구분한다

AI가 무엇을 하느냐보다 사람이 어디서 승인하느냐가 위임 수준을 정한다.

2

단계는 업무 단위마다 다르다

같은 회사 안에서도 데이터 수집은 4단계, 주문 실행은 3단계일 수 있다.

3

승급은 측정 결과로만 한다

성공률·개입률·수정률과 최대 손실 한도가 확인될 때 한 단계씩 올린다.

목표는 '완전 자동화'가 아니라 '통제 가능한 위임'이다

위임은 행동을 맡기되 결과 책임은 사람이 지는 구조다

delegation — 자동화(automation)와 달리 판단이 필요한 일을 AI 에이전트에게 맡기는 것

AI 에이전트 = 목표를 받으면 스스로 단계를 정해 도구를 쓰고 행동하는 AI

자동화 (automation)

- 정해진 규칙을 그대로 반복
- 예외 상황에서 멈춘다
- 예: 매일 9시 엑셀 매크로

위임 (delegation)

- 목표만 주면 방법은 AI가 판단
- 예외에도 대응하지만 실수 가능
- 그래서 승인 지점 설계가 필요

위임 사다리는 사람의 승인 지점에 따라 다섯 단계로 나뉜다

단계가 오를수록 AI 행동 범위는 넓어지고 사람의 사전 승인은 줄어든다



단계마다 AI와 사람의 역할, 필요한 통제가 다르다

한눈에 보는 0~4단계 — 아래 슬라이드에서 단계별로 자세히 다룬다

단계	AI가 하는 일	사람이 하는 일	핵심 통제
0단계	없음	전부	—
1단계	답변·초안·요약	판단과 모든 실행	불필요 (시스템 접근 없음)
2단계	실제 행동 실행	단계마다 승인	확인 창, 읽기 전용 계정
3단계	끝까지 실행	최종 외부 행동만 승인	승인 화면 근거, 한도, 로그
4단계	사전 승인 없이 실행	규칙 설정·사후 감사	규칙, 전수 로그, kill switch

0단계는 사람이 모든 일을 직접 하는 기준선이다

baseline — 이후 단계의 시간 절감과 오류율을 비교하는 출발점

AI 없음 · 측정의 기준선

예시 — 리서치·운용

- 애널리스트가 DART를 직접 검색
- 재무 수치를 엑셀에 손으로 입력
- 운용역이 주문 화면에 직접 입력

통제와 한계

- 소요 시간과 오류율을 먼저 잰다
- 이 숫자가 있어야 개선을 말할 수 있다

1단계에서 AI는 답하고 사람이 실행한다

advisor — 챗봇처럼 답변·초안만 내고 시스템에는 손대지 않는다

AI가 답변 · 사람이 실행

예시 — 리서치·운용

- 실적 발표문 요약
- 리포트 문단 초안 작성
- 수식·계산 검산

통제와 한계

- AI가 시스템에 접근하지 않아 위험이 낮다
- 사실 확인(hallucination 점검)은 사람 몫

2단계에서 AI는 실행하고 사람은 단계마다 승인한다

supervised execution — 행동 전 확인 창이 뜨고 사람이 허락해야 다음으로 간다

AI가 실행 · 단계마다 승인

예시 — 리서치·운용

- 공시 수집 → 확인 → 수치 추출
- → 확인 → 표 작성
- 포트폴리오 구성안 작성

통제와 한계

- 읽기 전용 계정, 행동 전 확인 창
- 한계: 사람이 계속 옆에 붙어 있어야 한다

3단계에서 사람은 외부로 나가는 마지막 행동만 승인한다

approve-to-release — 발간·발송·주문처럼 되돌리기 어려운 행동 직전에만 멈춘다

AI가 끝까지 실행 · 최종 행동만 승인

예시 — 리서치·운용

- 리포트 완성 → 애널리스트 검수 후 발간
- 리밸런싱 주문안 → 운용역 승인 후 주문
- 고객 보고서 → 확인 후 발송

통제와 한계

- 승인 화면에 근거 자료 첨부
- 금액·종목 한도, 실행 로그 보존

4단계에서 AI는 사전 승인 없이 실행하고 사람은 사후 감사한다

autonomous with audit — 규칙 안에서 자율 실행, 이상 시 즉시 중단

AI 자율 실행 · 사후 감사

예시 — 리서치·운용

- 밴드 이탈 시 자동 리밸런싱
- 정형 데이터 일일 보고서 배포
- 가격·공시 데이터 자동 수집

통제와 한계

- 사전 규칙: 한도·금지 행동 목록
- 전수 감사 로그 + 즉시 중단 장치(kill switch)

같은 회사 안에서도 업무마다 위임 단계가 다르다

자산운용사 예시 — 되돌리기 쉽고 정형적인 업무일수록 높은 단계에 둔다



측정 지표

세 가지 비율로 현재 단계의 운영 상태를 잰다

같은 업무를 N회 실행해 기록한다 — 2단계 이상에서 매주 집계

$$\hat{S} = \frac{N_{\text{success}}}{N_{\text{run}}}, \qquad \hat{I} = \frac{N_{\text{intervene}}}{N_{\text{run}}}, \qquad \hat{M} = \frac{N_{\text{edited}}}{N_{\text{approved}}}$$

기호	의미	읽는 법
S 성공률	결과가 기준을 통과한 비율	높을수록 맡길 수 있다
I 개입률	승인 외에 사람이 끼어든 비율	재지시·막힘 해소 횟수
M 수정률	승인 단계에서 사람이 고친 비율	0에 가까우면 승인이 형식화

승급은 성공률·수정률·최대 손실 세 조건을 모두 만족할 때만 한다

L_max: 실패 시 최대 손실, L̄: 감내 가능한 손실 한도

$$\text{Level } k \to k+1 \iff \hat{S} \geq 0.9, \quad \hat{M} \approx 0, \quad L_{\max} \leq \bar{L}$$

승급 조건

- 2→3: 10회 중 9회 이상 성공, 개입이 승인 확인 수준
- 3→4: 승인 단계 수정률이 거의 0
- 실패해도 손실이 한도 안에 갇힌다

강등 조건

- 한도 초과 손실이 한 번이라도 발생
- 사이트·시스템 변경으로 성공률 급락
- 원인 확인 전까지 한 단계 내린다

신문사 자동화 특강은 3단계 위임을 홍보한다

한국디지털언론협회 특강(2026.10.30) — Aside 브라우저로 기사 발행·SNS 확산 자동화

월 3~4개

도입 전 자체 발행 기사

하루 10개~

자동화 후 발행 기사(홍보 수치)

99% / 1%

자동화 / 사람 승인

사다리로 읽으면

- 기사 발행 직전에만 승인 → 3단계
- 백링크 확산은 확인만 → 3~4단계

확인할 점

- 승인 화면에서 무엇을 검토하는가
- 수정률이 0이면 승인이 형식화된 것

케이스 · Knight Capital

통제 없는 자율 실행은 45분 만에 회사를 무너뜨렸다

2012.8.1 미국 증권사 Knight Capital — 배포 오류로 자동 주문 시스템이 폭주 (출처: SEC 2013 제재 결정)

45분
폭주 지속 시간

4.6억 달러
손실 (SEC 발표)

400만 건+
154개 종목 체결 건수

무슨 일이 있었나

- 옛 코드가 남은 서버 1대가 대량 주문
- 이상 경보를 사람이 제때 해석 못 함

4단계의 교훈

- 주문 한도와 kill switch가 먼저다
- 자율 실행은 규칙·감사가 갖춰진 뒤

AI 리서치회사는 수집은 4단계, 발간은 3단계로 설계한다

리서치 리포트 발간 업무를 단위별로 나눠 현재 단계와 목표 단계를 정한 예시

업무 단위	시작 단계	목표 단계	승인자
공시·통계 데이터 수집	2	4	— (사후 감사)
수치 추출·검증	2	3	리서치 어시스턴트
리포트 초안 작성	1	3	담당 애널리스트
투자 의견·목표가	1	1	리서치 헤드
발간·뉴스레터 배포	2	3	컴플라이언스

투자 의견처럼 책임이 큰 판단은 1단계에 묶어 둔다

토론

우리 조직의 업무를 사다리에 올려 본다

각자 업무 하나를 골라 현재 단계와 다음 단계를 정한다

Q1	내 업무 중 지금 바로 2단계로 올릴 수 있는 것은 무엇인가	**출발점**
Q2	3단계 승인 화면에 반드시 보여야 할 근거는 무엇인가	**승인 설계**
Q3	우리 조직에서 4단계를 허용할 수 있는 업무가 있는가	**자율 한계**
Q4	수정률이 0이 되면 승인을 유지할 것인가, 없앨 것인가	**형식화**

위임 사다리는 AI 도입의 속도와 안전을 함께 관리하는 틀이다

다음 단계 — 실측으로 업무별 현재 단계를 판정한다

1 **승인 지점이 단계를 정한다**

0~4단계는 사람이 어디서 멈추고 확인하는지로 구분된다.

2 **업무 단위로 따로 정한다**

되돌리기 쉽고 정형적인 업무부터 높은 단계로 올린다.

3 **측정으로 올리고 사고로 내린다**

성공률·수정률·손실 한도로 승급하고, 한도 초과 시 즉시 강등한다.

현실적 목표는 3단계 — AI가 끝까지 실행하고 사람은 마지막에 승인한다